

Detecção de Domínios Maliciosos

Universidade Federal do Paraná - UFPR

Abner Fontebom Bissolli Costa
Michele Venturin

Dataset Escolhido e Distribuição dos Dados

Detaset e Motivação

— — —



- **Dataset:**

Conjunto 1M de domínios, previamente classificados como benignos, *malware*, *phishing* e *spam*. (CIC-Bell-DNS2021)

- **Motivação:**

“A cada ano, muitas grandes corporações são afetadas por essas ameaças, resultando em enormes perdas financeiras em um único ataque. Portanto, detectar e classificar um domínio malicioso em tempo hábil é essencial.”

Exemplos

— — —

Domínio	Class. Multiclasse	Class. Binária
<i>stockholm.se</i>	Benigno	Benigno
<i>ahackaday.io</i>	Benigno	Benigno
<i>arrow.com</i>	Benigno	Benigno
<i>paypal.de.daten.sicherheit-benutzer.top</i>	Malware	Malicioso
<i>businessbattle.tk</i>	Phishing	Malicioso
<i>k-slee.com</i>	Spam	Malicioso

Problema

- Problema:

Classificar corretamente domínios entre benignos e maliciosos, sem gerar muitos falsos alertas e ao mesmo tempo bloquear uma quantidade significativa de domínios maliciosos


- Proposta:

Gerar um algoritmo classificar que atuará em juntamente com uma lista branca.


Distribuição dos Dados

— — —

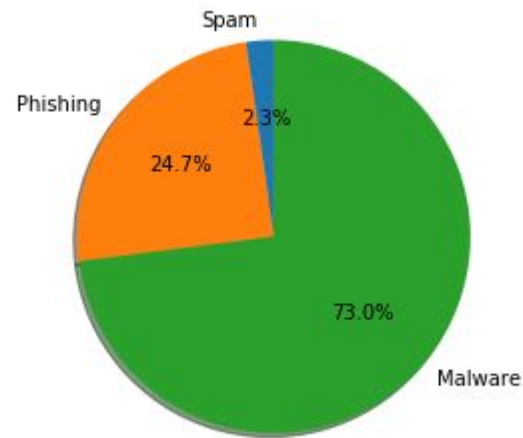
**Distribuição Original
(Be/Mw)**



**Distribuição Balanceada
(Be/Mw) (Treino/Teste)**



**Distribuição Classes
Maliciosos (Mw/Ph/Sp)**



Atributos e Características

Atributos

Os atributos foram gerados utilizando a biblioteca `tld` para Python3, a qual realiza o parsing do domínio.



Características

— — —

Características Léxicas (45)

Tamanho Subdomínio+SLD.
Entropia da string.
Número de caracteres não alfanuméricos (‘.’ e ‘-’)
Valor TF-IDF do TLD.
Tamanho da maior sequência de mesmos caracteres.

Características de Terceiros (13)

Nº de nomes registrados
Informações Privadas
Valor TF-IDF do TLD.
Nº de servidores registrado.
Menor distância do SLD para SLD famosos (Alexa Rank).

Codificação e Normalização

— — —

- Para a codificação de características textuais, foram utilizados os algoritmos *TF-IDF* e *LabelEncoder* (*sklearn*), com pequenas modificações.
- Após a codificação das variáveis textuais, foi realizada uma normalização utilizando utilizando a função *Normalizer* (*sklearn*).

Algoritmos Testados

Algoritmos Testados

— — —

Florestas Randômicas

Parâmetro	Definição
n_estimators	1000
max_depth	30
class_weight	“balanced”
random_state	42

Perceptron Multicamadas (MLP)

Parâmetro	Definição
n_neighbors	8
metric	“minkowski”
weights	“uniform”


K-Nearest Neighbors (KNN)

Parâmetro	Definição
hidden_layer_sizes	(50, 100, 50)
random_state	42
max_iter	1000
learning_rate_init	0.001
learning_rate	“adaptive”
validation_fraction	0.1
batch_size	32
early_stopping	True
verbose	True


Algoritmos Testados - *Tuning*

— — —

MLP - *Loss Value*




MLP - *Validation Score*



Algoritmos Testados - *Tuning*

— — —

KNN - Número de Vizinhos



Limiares definidos

Algoritmo	Limiar
Florestas Randômicas	0.435
MLP	0.466
KNN	0.4


Algoritmos Testados - Importância das Características

- **Características Léxicas:**

70%

- **Características de Terceiros:**

30%



Algoritmos Testados - Importância das Características

— — —

Número de Nomes Registrados.

Idade do Domínio.

Número de Servidores Registrados.

Número de Registradores Registrados.

Tamanho do SSD.

Menor número de caracteres distintos que compõe a maioria do SSD.

Tamanho da maior sequência de mesmos caracteres no SUB.

Tamanho do SUB.

Porcentagem do SSD que os 5 caracteres mais utilizados compreendem.

Menor Distância do SLD para SLD Famosos.

Resultados e Análise

Resultados - Métricas


Algoritmo	Acurácia	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>
Florestas Randômicas	0.799	0.799	0.798	0.799
Neurônio Multicamadas	0.797	0.798	0.795	0.796
<i>K-Nearest Neighbors</i>	0.763	0.748	0.792	0.769

Algoritmo	Pasta 1	Pasta 2	Pasta 3	Pasta 4	Pasta 5	Média
Florestas Randômicas	0.799	0.796	0.797	0.793	0.797	0.796
Neurônio Multicamadas	0.792	0.788	0.793	0.786	0.794	0.791
<i>K-Nearest Neighbors</i>	0.772	0.769	0.771	0.764	0.765	0.768


Resultados - Matrizes de Confusão

— — —


Florestas Randômicas



Perceptron Multicamadas (MLP)




K-Nearest Neighbors (KNN)



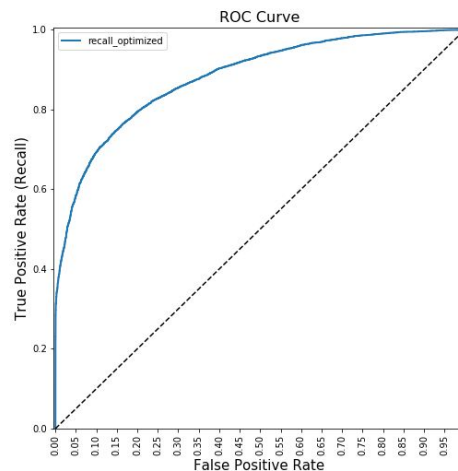
Resultados - Curvas ROC

— — —


Florestas Randômicas



Perceptron Multicamadas (MLP)



K-Nearest Neighbors (KNN)



Análise

— — —

- Através dos algoritmos testados, foi possível observar que todos os resultados ficam próximos a 80%.
- Este fato nos levou a acreditar que as características geradas não são capazes de solucionar o problema.

Análise

— — —

- Apenas dois tipos de características foram utilizadas **léxicas** e de **terceiro**. No entanto outras características podem ser exploradas, como dados da seção de resposta da resposta do DNS.
- Também é possível utilizar redes neurais recorrentes com palavras ou subdivisões do domínio, ou então utilizando técnicas como *n-grams*.

Demonstração

Referências

— — —

- Amazon (2021). Top 1M domains.
<http://s3.amazonaws.com/alexa-static/top-1m.csv.zip>.
Acessado em 07/12/2021.
- Bezerra, M. A. et al. (2015). Uma investigação do uso de características na detecção de urls.

Referências

— — —

- Davison, J., Moffitt, T., and and, H. L. (2019). Webroot cybersecurity. threat report – mid-year update.
- Mahdavifar, S., Maleki, N., Lashkari, A. H., Broda, M., and Razavi, A. H. (2021). Classifying malicious domains using dns traffic analysis.

Referências

— — —

- Olivo, C. K., Santin, A., and Oliveira, L. (2010). Avaliação de características para detecção de phishing de e-mail. Pontifícia Universidade Católica do Paraná, Curitiba-PR, Brasil.

Referências

— — —

- Ceschin, F., Oliveira, L. S., and Grégio, A. (2019). Aprendizado de máquina para segurança: Algoritmos e aplicações. Em Minicursos do XIX Simpósio Brasileiro de Segurança da Informação e de Sistemas Computacionais. Capítulo 2, páginas 41–90. SBSeg.